

Raport z projektu “Optymalizacja Portfela Inwestycyjnego” z przedmiotu Nieklasyczne Metody Optymalizacji

Autorzy:

- Nicola Kulesza 148977
- Alicja Żebiałowicz 149317
- Mikołaj Kadłubowski 149300
- Jakub Szubert 121652

Link do repozytorium na Githubie: <https://github.com/miki3581/Portfolio-optimization>

1. Matematyczne sformułowanie problemu i charakterystyka danych	3
1.1. Model teoretyczny portfela Markowitza	3
1.2. Charakterystyka i przygotowanie danych empirycznych	4
2. Klasyczne rozwiązanie referencyjne (Benchmark)	5
2.1. Metoda optymalizacji i implementacja numeryczna	5
2.2. Wyznaczanie Portfela o Minimalnej Wariancji (MVP) oraz Granicy Efektywnej	5
2.3. Analiza uzyskanych wyników klasycznych	6
3. Algorytm symulowanego wyżarzania	7
3.1. Mechanika funkcji celu z karą	7
3.2. Rzutowanie wag na sympleks	7
3.3. Szczegóły implementacji	8
3.4. Analiza wyników i wykresy zbieżności	8
3.4.1 Harmonogram chłodzenia	8
3.4.2 Zbieżność funkcji celu	9
3.4.3 Struktura optymalnego portfela	10
3.4.4. Walidacja na tle granicy efektywności Markowitza	10
4. Algorytm genetyczny	12
4.1. Opis wstępny	12
4.2. Reprezentacja chromosomowa i dekodowanie wag	12
4.3. Funkcja celu z karą	13
4.4. Mechanizmy operatorów genetycznych	13
4.4.1. Selekcja metodą ruletki	13
4.4.2. Krzyżowanie jednopunktowe	13
4.4.3. Mutacja bitflip	14
4.4.4. Elityzm	14
4.5. Implementacja algorytmu	14
4.6. Analiza wyników i wykresy zbieżności	14
4.6.1. Zbieżność funkcji celu	15
4.6.2. Ewolucja wag najlepszego osobnika	16
4.6.3. Struktura optymalnego portfela	16
4.6.4. Walidacja na tle granicy efektywności Markowitza	17
5. Zintegrowana analiza porównawcza algorytmów	18
5.1. Cel i zakres prac	18
5.2. Opis implementacji i integracji modułów	18
5.2.1. Metodologia integracji	18
5.2.2. Benchmark klasyczny (Granica efektywna)	19
5.2.3. Grid Search (Strojenie hiperparametrów)	19
Symulowane wyżarzanie – współczynnik chłodzenia	19
Algorytm genetyczny – wielkość populacji pop_size	20
5.2.4. Analiza wrażliwości	20
5.2.5. Analiza wizualna (Wykresy porównawcze)	21
5.3. Pliki wyjściowe i struktura katalogów	22
5.4. Główne wnioski z analizy	22
6. Bibliografia	23

1. Matematyczne sformułowanie problemu i charakterystyka danych

1.1. Model teoretyczny portfela Markowitza

Klasyczny model średnia-wariancja Harry'ego Markowitza stanowi fundament nowoczesnej teorii portfelowej. Problem optymalizacji polega na alokacji kapitału pomiędzy n dostępnych aktywów finansowych w taki sposób, aby zminimalizować ryzyko mierzone wariancją (lub odchyleniem standardowym) stóp zwrotu portfela, przy założeniu osiągnięcia określonej, docelowej stopy zwrotu.

Niech $w = [w_1, w_2, \dots, w_n]^T$ oznacza wektor wag aktywów w portfelu, gdzie w_i to udział kapitału ulokowany w i -te aktywo. Zakładamy pełną alokację kapitału oraz brak możliwości krótkiej sprzedaży.

Oczekiwana stopa zwrotu z portfela $E(R_p)$ oraz roczna wariancja portfela σ_p^2 wyrażają się wzorami:

$$E(R_p) = w^T \mu = \sum_{i=1}^n w_i \mu_i$$
$$\sigma_p^2 = w^T \Sigma w = \sum_{i=1}^n \sum_{j=1}^n w_i w_j \sigma_{ij}$$

Gdzie:

- $\mu = [\mu_1, \mu_2, \dots, \mu_n]$ to wektor oczekiwanych (skonstruowanych historycznie) rocznych stóp zwrotu aktywów.
- Σ to macierz kowariancji rocznych stóp zwrotu aktywów o wymiarach $n \times n$, gdzie σ_{ij} oznacza kowariancję między stopami zwrotu aktywa i oraz j (dla $i = j$ jest to wariancja σ_i^2).

Formalny model optymalizacyjny z ograniczeniami dla wyznaczenia portfela efektywnego o zadanym poziomie stopy zwrotu R_{target} przyjmuje postać:

$$\min_w f(w) = w^T \Sigma w$$

przy ograniczeniach:

1. Ograniczenie budżetowe (pełna alokacja): $\sum_{i=1}^n w_i = 1$
2. Ograniczenie stopy zwrotu: $w^T \mu = R_{target}$
3. Brak krótkiej sprzedaży: $0 \leq w_i \leq 1 \quad \forall i \in \{1, 2, \dots, n\}$

1.2. Charakterystyka i przygotowanie danych empirycznych

Do celów badawczych wykorzystano rzeczywiste dane rynkowe pobrane za pomocą skryptu `downloader.py` przy użyciu biblioteki `yfinance`. Analizą objęto portfel składający się z $n=15$ płynnych spółek notowanych na Giełdzie Papierów Wartościowych w Warszawie (GPW), reprezentujących kluczowe sektory polskiej gospodarki. Dane obejmują dzienny interwał czasowy z okresu ostatnich 3 lat (maj 2023 – maj 2026).

Skład portfela przedstawia poniższa tabela:

Ticker GPW	Nazwa Spółki / Sektor	Ticker GPW	Nazwa Spółki / Sektor
PKN.WA	Orlen (Energetyka/Paliwa)	CDR.WA	CD Projekt (Gaming)
PKO.WA	PKO BP (Bankowość)	DNP.WA	Dino Polska (Handel detaliczny)
PEO.WA	Pekao SA (Bankowość)	MBK.WA	mBank (Bankowość)
KGH.WA	KGHM (Górnictwo/Miedź)	ALR.WA	Alior Bank (Bankowość)
PZU.WA	PZU (Ubezpieczenia)	TPE.WA	Tauron (Energetyka)
LPP.WA	LPP (Odzieżowy)	PGE.WA	PGE (Energetyka)
ALE.WA	Allegro (E-commerce)	BDX.WA	Budimex (Budownictwo)
SPL.WA	Santander Bank Polska (Bankowość)		

W etapie przetwarzania danych (`data_loader.py`) przekształcono dzienne ceny zamknięcia (P_t) w logarytmiczne stopy zwrotu, zgodnie z formułą:

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right)$$

Logarytmiczne stopy zwrotu zapewniają pożądaną w modelach ciągłych stabilność statystyczną oraz addytywność w czasie. Parametry wejściowe modelu zostały poddane procedurze rocznej skali (annualizacji) przyjmując standardową liczbę 252 dni sesyjnych w roku:

- Wektor oczekiwanych stóp zwrotu (μ): średnia dzienna stopa zwrotu pomnożona przez 252.
- Macierz kowariancji (Σ): dzienna macierz kowariancji pomnożona przez 252.

2. Klasyczne rozwiązanie referencyjne (Benchmark)

2.1. Metoda optymalizacji i implementacja numeryczna

W celu weryfikacji jakości działania algorytmów nieklasycznych (które zgodnie z założeniami projektu zostaną zaimplementowane samodzielnie od podstaw), w pierwszej kolejności wyznaczono dokładne matematyczne rozwiązanie referencyjne. Zaimplementowano je w module `markovitz.py`.

Do rozwiązania kwadratowego problemu optymalizacji z ograniczeniami liniowymi wykorzystano klasyczny solver numeryczny `scipy.optimize.minimize` z algorytmem SLSQP (*Sequential Least Squares Programming*). Jest to metoda gradientowa, która w każdej iteracji aproksymuje problem programowania nieliniowego za pomocą podproblemu programowania kwadratowego (QP) i skutecznie radzi sobie z ograniczeniami równościowymi oraz nierównościowymi.

2.2. Wyznaczanie Portfela o Minimalnej Wariancji (MVP) oraz Granicy Efektywnej

Proces budowy benchmarku przebiegał w dwóch głównych fazach:


1. Wyznaczenie Portfela o Minimalnej Wariancji (MVP - *Minimum Variance Portfolio*):
Rozwiązano problem minimalizacji zmienności σ_p przy aktywnym ograniczeniu budżetowym $\sum w_i = 1$ oraz braku krótkiej sprzedaży, pomijając chwilowo warunek stopy zwrotu. Uzyskany punkt stanowi globalne minimum ryzyka, pod którym żaden portfel nie może istnieć. Wynik ten posłużył jako dolne ograniczenie stopy zwrotu przy generowaniu granicy efektywnej.
2. Konstrukcja Granicy Efektywnej (*Efficient Frontier*):
Przestrzeń poszukiwań stóp zwrotu została zdyskretyzowana na 50 równomiernych punktów z przedziału:

$$R_{target} \in [R_{MVP}, \max(u_i)]$$

Dla każdego z 50 punktów uruchomiono algorytm SLSQP, który precyzyjnie dopasował optymalną strukturę wag w^* , minimalizując odchylenie standardowe portfela.

2.3. Analiza uzyskanych wyników klasycznych

Na podstawie eksperymentu wykonanego w pliku test.ipynb wygenerowano krzywą obrazującą relację zysku do ryzyka (Markowitz Efficient Frontier).



Wizualizacja wyników pozwoliła na zlokalizowanie portfela MVP (oznaczonego na wykresie czerwoną gwiazdą) oraz przebiegu samej granicy. Uzyskana krzywa charakteryzuje się gładkim, wypukłym kształtem, co jest bezpośrednią konsekwencją efektu dywersyfikacji w portfelu złożonym z 15 częściowo skorelowanych ze sobą aktywów.

Wartości uzyskane za pomocą algorytmu SLSQP reprezentują teoretyczne, ciągłe optima globalne dla analizowanego zbioru danych. Wyniki te (wagi aktywów, minimalne ryzyko i odpowiadające im stopy zwrotu) zostaną zapisane w ustandaryzowanych strukturach danych (słownikach języka Python zawierających m.in. klucze `x_opt` oraz `f_opt`) i posłużą w dalszej części raportu jako bezwzględny punkt odniesienia (benchmark) do oceny zbieżności, dokładności oraz efektywności obliczeniowej autorskich implementacji algorytmów metaheurystycznych: Symulowanego Wyżarzania (SA) oraz Algorytmu Genetycznego (GA).

3. Algorytm symulowanego wyżarzania

Rozwiązanie problemu optymalizacji portfela zostało zrealizowane poprzez adaptację klasycznego algorytmu symulowanego wyżarzania (bazującego na skryptach z zajęć). W kontekście optymalizacji portfelowej, przestrzenią poszukiwań jest zbiór wszystkich możliwych wag przypisanych poszczególnym akcjom, a celem jest minimalizacja ryzyka przy jednoczesnym spełnieniu założonego progu rentowności.

3.1. Mechanika funkcji celu z karą

W implementacji z wykorzystaniem symulowanego wyżarzania zastosowano podejście relaksacyjne – ograniczenie na zwrot zostało włączone do funkcji celu jako kara za niedowiezienie wyniku.

Minimalizowana funkcja celu przyjmuje postać:

$$f(w) = w^T \Sigma w + \lambda \max(0, R_{target} - w^T \mu)$$

- w – wektor wag portfela
- Σ – macierz kowariancji stóp zwrotu
- μ – wektor oczekiwanych stóp zwrotu
- R_{target} – docelowa stopa zwrotu (w modelu ustawiona na 15%)
- λ – waga kary (w głównym wywołaniu algorytmu przyjęto 500)

Mechanizm ten silnie zniechęca algorytm do akceptacji rozwiązań nierentownych. Z kolei w sytuacji, gdy portfel osiąga lub przekracza docelowy zwrot $R_{target} \leq w^T \mu$, kara ulega wyzerowaniu, a algorytm optymalizacyjny skupia się wyłącznie na znalezieniu alokacji o najmniejszym ryzyku.

3.2. Rzutowanie wag na sympleks

Z perspektywy finansowej portfel musi spełniać dwa ograniczenia:

1. $w_i \geq 0$ dla każdego i

2. $\sum_{i=1}^n w_i = 1$

W kodzie korekta wag portfela odbywa się za pomocą algorytmu optymalizacyjnego, który minimalizuje odległość euklidesową między wektorem zaburzonym a sympleksem. Pozwala to uniknąć naiwnego ucinania wartości ujemnych do zera i precyzyjnie wskazać najbliższy dopuszczalny wektor wag.

3.3. Szczegóły implementacji

Adaptacja skryptu bazowego obejmowała kilka kluczowych mechanizmów, decydujących o skuteczności stochastycznej optymalizacji:


1. Nowe rozwiązania generowane są poprzez dodanie losowej perturbacji o rozkładzie normalnym. Aby zwiększyć efektywność przeszukiwania, skala perturbacji maleje wraz ze spadkiem temperatury: algorytm dokonuje szerszej eksploracji na początku, a pod koniec procesu precyzyjnie dostraja wagi.
2. Zastosowano geometryczny schemat spadku temperatury opisany wzorem $T_k = T_0 \alpha^k$, gdzie T_0 to temperatura początkowa, a α to współczynnik stygnięcia dla iteracji k .
3. Kandydat lepszy od obecnego rozwiązania jest akceptowany zawsze. Kandydat gorszy (zwiększający wartość funkcji celu o Δ) jest akceptowany z prawdopodobieństwem $P = \exp(-\Delta/T)$. Mechanizm ten pozwala algorytmowi uciec z minimów lokalnych, zwłaszcza we wczesnej fazie działania.

3.4. Analiza wyników i wykresy zbieżności

Aby zweryfikować poprawność adaptacji algorytmu do problemu finansowego, przeanalizowano wyniki dla 8000 iteracji przy początkowej temperaturze $T_0 = 2$. Wyniki działania algorytmu poddano ewaluacji wizualnej na podstawie wygenerowanych wykresów.

3.4.1 Harmonogram chłodzenia


Zastosowany w algorytmie geometryczny schemat spadku temperatury jest kluczowy dla balansu między eksploracją przestrzeni (wysoka temperatura) a eksploatacją i precyzyjnym dostrajaniem wag (niska temperatura).



Wykres potwierdza prawidłowy, wykładniczy spadek parametru T . W początkowych 2000 iteracji temperatura gwałtownie spada z poziomu 2.0 do okolic 0.25, co pozwala algorytmowi na swobodne przeskakiwanie między różnymi alokacjami aktywów. W późniejszej fazie (powyżej 4000 iteracji) temperatura zbliża się asymptotycznie do zera, co sprawia, że algorytm zamienia się w deterministyczne przeszukiwanie lokalne (akceptowane są już niemal wyłącznie lepsze rozwiązania).

3.4.2 Zbieżność funkcji celu


Proces "uczenia się" i optymalizacji portfela najlepiej obrazuje śledzenie wartości funkcji celu.



Na wykresie wyraźnie widać charakterystykę symulowanego wyżarzania. Niebieska linia (wartość bieżąca) wykazuje dużą zmienność na początku optymalizacji, co dowodzi, że algorytm wielokrotnie akceptował gorsze rozwiązania kandydujące, aby uciec z minimów lokalnych. Pomarańczowa linia (najlepsza wartość dotąd) bardzo szybko stabilizuje się na niskim poziomie, co świadczy o wysokiej efektywności zastosowanej metody rzutowania na sympleks Duchi'ego. Pod koniec procesu obie linie zlewają się, osiągając globalne minimum pod postawionymi ograniczeniami.

3.4.3 Struktura optymalnego portfela


Kluczowym wynikiem działania algorytmu jest wektor wag przypisanych poszczególnym aktywom.



Słupkowa wizualizacja struktury wygenerowanego portfela empirycznie weryfikuje poprawne działanie algorytmu projekcji na sympleks. Wszystkie wagi są nieujemne (brak krótkiej sprzedaży), a ich wizualna suma wynosi 1.0 (pełne zainwestowanie kapitału). Portfel charakteryzuje się dość silną dywersyfikacją, przy czym dominujący udział mają aktywa o indeksach 10 (ok. 23%), 12 (ok. 20%), 0 (ok. 17%) oraz 4 (ok. 15%). Reszta kapitału została rozdzielona w mniejszych proporcjach pomiędzy pozostałe, wybrane akcje. Algorytm samoistnie wyzerował wagi aktywów o słabym stosunku zwrotu do ryzyka.

3.4.4. Walidacja na tle granicy efektywności Markowitza

Potwierdzeniem poprawności użytej heurystyki jest zestawienie jej z rozwiązaniem analitycznym/deterministycznym.



Wykres zestawia wynik uzyskany stochastyczną metodą symulowanego wyżarzania (czerwony punkt) z analitycznie wyznaczoną krzywą Markowitza (niebieska linia). Zoptymalizowany portfel charakteryzuje się zwrotem na poziomie 18.43% przy odchyleniu standardowym 18.67%. Punkt ten plasuje się bezpośrednio na lewym skraju granicy efektywności (w portfelu o minimalnej wariancji dla danego poziomu zwrotu). Jest to dowód na to, że mimo zastosowania metody probabilistycznej z funkcją kary, zaimplementowany algorytm poprawnie odnalazł optymalne rozwiązanie problemu alokacji kapitału.

4. Algorytm genetyczny

4.1. Opis wstępny

W celu znalezienia optymalnego portfela Markowitza w badaniu zastosowano również algorytm genetyczny. W odróżnieniu od klasycznego algorytmu wyżarzania symulowanego omawianego w rozdziale 3., który utrzymuje i udoskonala jedno rozwiązanie, algorytm genetyczny wykorzystuje populację rozwiązań kandydackich. Nowe rozwiązania powstają poprzez łączenie i modyfikację osobników z poprzedniego pokolenia.

4.2. Reprezentacja chromosomowa i dekodowanie wag

W pierwszym kroku analizy rozpatrywano dobór właściwej reprezentacji wektora wag portfela Markowitza. Podjęto decyzję, by wykorzystać kodowanie binarne. Do tego celu służy zmienna *bits_per_gene* równa 16 bitów. Łącznie, po przemnożeniu przez każdą z 15 akcji portfela, daje to 240 bitów.

Samo dekodowanie wag na bity przebiega dwuetapowo:

1. Zamiana fragmentów bitowych na wartości rzeczywiste

Każdy gen, czyli 16-bitowy fragment chromosomu podlega interpretacji liczbowej za pomocą metody MSB-first, czyli najbardziej znaczący bit na początku. W kolejnym kroku gen zostaje skalowany do przedziału $[0;1]$.

2. Normalizacja do sympleksu

Surowe wartości z kroku 1 sumuje się wierszami, a następnie każdy wiersz dzieli przez tę sumę. Dzięki temu automatycznie spełnione są oba ograniczenia portfelowe:

$$w_i \geq 0 \text{ dla każdego } i$$

$$\sum_{i=1}^n w_i = 1$$

Powodem zastosowania opisanego wyżej podejścia jest chęć eliminacji konieczności projekcji na sympleks jako oddzielnego kroku (tak, jak wykonywane jest to w rozdziale 3.). Konstrukcja dekodowania zapewnia spełnienie ograniczeń. Opisywany tu algorytm posiada zabezpieczenie przed ewentualnym dzieleniem przez zero w postaci zamiany sumy zerowej na wartość 1.0 – skutkuje to portfelem o równych wagach.

4.3. Funkcja celu z karą

Funkcja celu jest identyczna jak w wersji z symulowanym wyżarzaniem – zastosowano to samo podejście relaksacyjne, w którym ograniczenie na zwrot zostało włączone do funkcji minimalizowanej jako kara. Funkcja ma poniższą postać:

$$f(\mathbf{w}) = \mathbf{w}^\top \Sigma \mathbf{w} + \lambda \cdot \max(0, R_{\text{target}} - \mathbf{w}^\top \boldsymbol{\mu})$$

gdzie:

- $\mathbf{w}$ – wektor wag portfela
- Σ – macierz kowariancji stóp zwrotu
- $\boldsymbol{\mu}$ – wektor oczekiwanych stóp zwrotu
- R_{target} – docelowa stopa zwrotu (ustawiona na 15%)
- λ – waga kary (przyjęto $\lambda = 500$)

Gdy portfel osiąga lub przekracza docelowy zwrot, kara ulega wyzerowaniu, a algorytm skupia się wyłącznie na minimalizacji wariancji. Gdy zwrot nie jest osiągnięty, kara liniowo rośnie wraz z niedoborem, silnie penalizując takie rozwiązania.

4.4. Mechanizmy operatorów genetycznych

Pętla główna algorytmu realizuje w każdym pokoleniu cztery kolejne kroki: selekcję, krzyżowanie, mutację oraz (opcjonalnie) elityzm.

4.4.1. Selekcja metodą ruletki

Prawdopodobieństwo wyboru osobnika do reprodukcji jest proporcjonalne do jego przystosowania, zdefiniowanego jako odwrotność wartości funkcji celu przeskalowana przez wartość minimalną w populacji:

$$\text{przystosowanie}_i = \frac{\min_j f(\mathbf{w}_j)}{f(\mathbf{w}_i)}$$

Tak obliczone wartości są normalizowane do rozkładu prawdopodobieństwa. Losowanie rodziców odbywa się z powtarzaniem poprzez odwrócenie dystrybucji skumulowanej (metoda *CDF inverse*). Osobniki o mniejszej wartości funkcji celu mają tym samym większą szansę na przekazanie swoich genów potomstwu, jednak z uwagi na losowy charakter selekcji słabsze osobniki nie są całkowicie eliminowane.

4.4.2. Krzyżowanie jednopunktowe

Dla każdego potomka losowo wybierany jest pierwszy rodzic (z puli wyłonionej przez ruletkę) oraz niezależnie drugi rodzic. Następnie losowany jest punkt podziału chromosomu. Potomek dziedziczy pierwszą część chromosomu od pierwszego rodzica, a pozostałą część od drugiego. Mechanizm ten pozwala na rekombinację cech obojga rodziców – korzystne fragmenty alokacji z różnych osobników mogą zostać połączone w jednym potomku.

4.4.3. Mutacja bitflip

Po krzyżowaniu każdy bit chromosomu jest niezależnie odwracany z prawdopodobieństwem $p_{mut} = 0,005$. Mutacja pełni rolę operatora eksploracji – zapobiega przedwczesnej zbieżności populacji do optimum lokalnego i wprowadza do puli genowej nowe kombinacje wag, które krzyżowanie samo w sobie nie byłoby w stanie wygenerować.

4.4.4. Elityzm

Przed zastąpieniem starej populacji nową, chromosom najlepszego osobnika z bieżącego pokolenia jest kopiowany bezpośrednio na pierwsze miejsce nowej populacji. Mechanizm ten gwarantuje, że globalne optimum znalezione do danego momentu nie zostanie utracone przez przypadkowe efekty selekcji lub mutacji, co znacząco stabilizuje zbieżność algorytmu.

4.5. Implementacja algorytmu

Algorytm uruchomiono z następującymi parametrami:


Parametr	Wartość
Liczba osobników w populacji (pop_size)	150
Liczba bitów na gen (bits_per_gene)	16
Prawdopodobieństwo mutacji (p_mut)	0,005
Liczba pokoleń (K)	400
Docelowa stopa zwrotu (target_return)	15%
Kara za shortfall (penalty)	500
Elityzm	Tak

Inicjalizacja populacji odbywa się przez losowanie każdego bitu niezależnie z prawdopodobieństwem 0.5, co odpowiada jednostajnemu rozkładowi na przestrzeni chromosomów i zapewnia szeroki zasięg eksploracji od pierwszego pokolenia.

4.6. Analiza wyników i wykresy zbieżności

Aby zweryfikować poprawność adaptacji algorytmu genetycznego do problemu finansowego, przeanalizowano wyniki dla 400 pokoleń przy populacji liczącej 150 osobników. W głównym uruchomieniu (ziarno losowości = 42) algorytm zbiegł do wartości funkcji celu równej 0,035472, czemu odpowiada portfel o oczekiwanym zwrocie 19,55% oraz ryzyku 18,83% (współczynnik Sharpe'a $\approx 1,038$ przy stopie wolnej od ryzyka $r_f = 0$); czas obliczeń wyniósł ok. 25,42 s. Wyniki działania algorytmu poddano dalej ewaluacji wizualnej na podstawie wygenerowanych wykresów.


4.6.1. Zbieżność funkcji celu



Proces optymalizacji portfela najlepiej obrazuje śledzenie wartości funkcji celu w kolejnych pokoleniach. W odróżnieniu od symulowanego wyżarzania, gdzie wartość bieżąca podlegała gwałtownym wahaniom (efekt akceptacji gorszych rozwiązań kandydujących), w algorytmie genetycznym z elityzmem obie krzywe – najlepszy osobnik w danym pokoleniu (linia niebieska) oraz najlepsza wartość dotąd (linia pomarańczowa) – praktycznie się pokrywają. Niebieska linia jest niemal w całości przesłonięta pomarańczową, ponieważ wynika to bezpośrednio z mechanizmu elityzmu: skoro najlepszy chromosom z poprzedniego pokolenia jest zawsze kopiowany do nowej populacji, minimalna wartość funkcji celu w pokoleniu nigdy nie może wzrosnąć. Przebieg jest zatem monotonicznie nierosnący – globalne optimum może być wyłącznie utrzymywane lub poprawiane, nigdy tracone.


Wykres ujawnia charakterystyczny dla algorytmów genetycznych, schodkowy spadek wartości funkcji celu. We wczesnej fazie (pierwsze ok. 80 pokoleń) widoczne są intensywne, skokowe poprawy – od poziomu ok. 0,041 do ok. 0,0364 – odpowiadające fazie eksploracji, w której krzyżowanie i mutacja szybko odkrywają coraz korzystniejsze kombinacje wag. Po ok. 150. pokoleniu tempo poprawy wyraźnie maleje, a krzywa stabilizuje się w okolicach 0,0357, co świadczy o zbieżności populacji wokół obszaru optymalnego. Globalne optimum było faktycznie poprawiane jedynie w 13,5% pokoleń – w pozostałych elitarny chromosom był wyłącznie podtrzymywany, co odpowiada płaskim odcinkom schodkowej krzywej. Pojedyncze, drobne uskoki w późniejszych pokoleniach (m.in. okolice pokolenia 295) odpowiadają sporadycznym udanym mutacjom, które nieznacznie udoskonalają elitarny chromosom, prowadząc do końcowej wartości 0,035472.

4.6.2. Ewolucja wag najlepszego osobnika



Wykres ewolucji wag najlepszego osobnika przez kolejne pokolenia pozwala prześledzić, w jaki sposób algorytm stopniowo kształtuje strukturę portfela. We wczesnych pokoleniach (do ok. 50.) poszczególne wagi podlegają dużym, gwałtownym wahaniom – odpowiada to fazie intensywnej eksploracji, w której operatory genetyczne swobodnie przemieszczają się po przestrzeni rozwiązań. Wraz z postępem optymalizacji linie stabilizują się: część wag zbiega do wyraźnie dodatnich poziomów (aktywa wybrane do portfela), a pozostałe – do wartości marginalnych (aktywa odrzucone). Charakterystyczne, schodkowe przeskokki widoczne na całej długości wykresu (np. w okolicach pokoleń 295 oraz 350) są bezpośrednim efektem elityzmu – w momencie znalezienia lepszego osobnika cały wektor wag zostaje skokowo zastąpiony nową, korzystniejszą alokacją. Po ok. 200. pokoleniu struktura portfela jest już niemal ustalona, co potwierdza zbieżność zaobserwowaną na wykresie funkcji celu.


4.6.3. Struktura optymalnego portfela



Słupkowa wizualizacja wag optymalnego portfela pozwala ocenić stopień dywersyfikacji oraz empirycznie potwierdza poprawność mechanizmu normalizacji do sympleksu zastosowanego w dekodowaniu chromosomu. Wszystkie wagi są nieujemne (brak krótkiej sprzedaży), a ich suma wynosi dokładnie 1,0 (pełna alokacja kapitału) – co jest bezpośrednim efektem konstrukcji dekodowania, a nie oddzielnego kroku projekcji. Portfel charakteryzuje się selektywną koncentracją kapitału: dominujący udział mają aktywa o indeksach 10 (17,77%), 12 (17,59%), 0 (16,28%) oraz 4 (13,26%), uzupełnione średnimi pozycjami w aktywach 2 (9,87%) i 3 (9,74%). Pozostały kapitał rozdzielono w coraz mniejszych proporcjach (aktywo 14 – 5,80%, aktywo 6 – 3,83%, aktywa 9 i 1 – odpowiednio 1,84% i 1,76%), aż po pozycje śladowe (indeksy 11, 5, 13, 8, 7 – od 0,80% do 0,14%).

Warto zwrócić uwagę na różnicę względem symulowanego wyżarzania: o ile metoda z rzutowaniem na sympleks twardo wyzerowała wagi najmniej efektywnych aktywów, o tyle algorytm genetyczny zachował dodatnie udziały we wszystkich 15 aktywach (minimalna waga 0,14%, liczba aktywów o wadze $> 0,1\%$ równa 15). Wynika to wprost z przyjętej reprezentacji binarnej z normalizacją – waga osiąga zero tylko wtedy, gdy wszystkie 16 bitów genu jest wyzerowanych, co w praktyce nie zachodzi. Mimo to algorytm zgodnie wskazał ten sam zestaw dominujących aktywów (10, 12, 0, 4) co symulowane wyżarzanie, co stanowi wzajemne potwierdzenie poprawności obu heurystyk.

4.6.4. Walidacja na tle granicy efektywności Markowitza



Ostatecznym potwierdzeniem poprawności użytej heurystyki jest zestawienie jej wyniku z granicą efektywności. Wykres przedstawia wynik algorytmu genetycznego (czerwony punkt) na tle chmury 20 000 losowych portfeli wygenerowanych metodą Monte Carlo (rozkład wykładniczy normalizowany do sympleksu) oraz aproksymowanej granicy efektywności (niebieska linia), wyznaczonej jako minimalne ryzyko w kolejnych przedziałach stopy zwrotu. Zoptymalizowany portfel charakteryzuje się zwrotem 19,55% przy odchyleniu standardowym 18,83%, czemu odpowiada współczynnik Sharpe'a na poziomie 1,038.

Czerwony punkt plasuje się na lewym skraju chmury punktów Monte Carlo, w bezpośrednim sąsiedztwie wyznaczonej granicy – co oznacza, że dla osiągniętego poziomu zwrotu algorytm odnalazł portfel o praktycznie minimalnym możliwym ryzyku. Warto zauważyć, że uzyskany zwrot (19,55%) z naddatkiem przekracza docelowy próg 15%, dzięki czemu składnik kary za shortfall ulega wyzerowaniu, a algorytm w praktyce minimalizuje czystą wariancję (stąd końcowa wartość funkcji celu 0,035472 odpowiada samej wariancji portfela). Umieszczenie punktu na lewej krawędzi chmury, w pobliżu aproksymowanej granicy, jest dowodem na to, że mimo zastosowania metody stochastycznej z funkcją kary algorytm genetyczny poprawnie odnalazł rozwiązanie bliskie Pareto-optimalnemu dla zadanego ograniczenia na zwrot.

5. Zintegrowana analiza porównawcza algorytmów

5.1. Cel i zakres prac

Ostatnim etapem prac badawczych była integracja stworzonych metaheurystyk w jedno spójne środowisko testowe w celu przeprowadzenia kompleksowej analizy porównawczej. Główne zadania zrealizowane w tej części obejmowały:

1. Zintegrowanie implementacji Symulowanego Wyżarzania (SA) i Algorytmu Genetycznego (GA) w jedno spójne środowisko testowe.
2. Przeprowadzenie analizy porównawczej (Grid Search) dla wybranych hiperparametrów obu metod:
 - SA: współczynnik chłodzenia $\alpha \in \{0.80, 0.90, 0.99, 0.995, 0.999\}$
 - GA: wielkość populacji *pop_size* $\in \{50, 150, 300\}$
3. Zaimplementowanie benchmarku klasycznego – zarówno numerycznej (scipy SLSQP, $w_i \geq 0$), jak i analitycznej (mnożniki Lagrange'a, krótka sprzedaż dozwolona) granicy efektywnej.
4. Przeprowadzenie analizy wrażliwości badającej stabilność algorytmów względem ziarna losowości (5 niezależnych uruchomień: seedy {16, 123, 234, 2026, 9999}).
5. Przygotowanie wizualizacji wyników (wykresy zbieżności i granicy efektywnej).
6. Zapis wyników liczbowych do pliku *tabele_wynikow.md*.

Wszystkie zadania zostały zrealizowane w skrypcie *Analiza_porownawcza.py*.

5.2. Opis implementacji i integracji modułów

5.2.1. Metodologia integracji

Skrypt importuje funkcje optymalizacyjne bezpośrednio z plików grupy:

Moduł	Importowana funkcja	Opis
Algorytm_SA.py	symulowane_wyzarzanie_portfel	SA z rzutowaniem na sympleks
Algorytm_genetyczny.py	algorytm_genetyczny_portfel	GA z kodowaniem binarnym
data_loader.py	mu, sigma	Annualizowane dane WIG15
markovitz.py	minimum_variance, efficient_return, analytical_efficient_frontier	Benchmark Markowitza (SciPy)

Oba algorytmy przyjmują ustandaryzowany interfejs: (mu, sigma, target_return, penalty, ..., rng). Ziarno losowości (rng) jest zawsze przekazywane jawnie – gwarantuje to powtarzalność wyników.

5.2.2. Benchmark klasyczny (Granica efektywna)

Na wykresie ryzyko–zwrot (znajdującym się w dalszej części raportu) naniesione są dwie granice efektywne z modułu markovitz.py:

- Numeryczna (scipy SLSQP, $w_i \geq 0$) – realistyczny benchmark bez krótkiej sprzedaży.
- Analityczna (metoda mnożników Lagrange'a, Σ^{-1} wyznaczone przez numpy.linalg.solve) – granica teoretyczna, dopuszczająca krótką sprzedaż; stanowi dolne ograniczenie ryzyka.

5.2.3. Grid Search (Strojenie hiperparametrów)

Symulowane wyżarzanie – współczynnik chłodzenia α

Testowane wartości: $\alpha \in \{0.80, 0.90, 0.99, 0.995, 0.999\}$

Stałe parametry: n_iter = 5000, T0 = 2,0, step_size = 0,1, RNG_SEED = 16

α	Funkcja celu	Stopa zwrotu	Ryzyko	Czas [s]
0.8000	0.034818	19.92%	18.66%	0.611
0.9000 ★	0.034787	19.11%	18.65%	0.613
0.9900	0.034825	19.51%	18.66%	0.607
0.9950	0.034794	19.61%	18.65%	0.614
0.9990	0.038436	22.69%	19.61%	0.622

Zaobserwowane zależności:

- Zbyt szybkie chłodzenie ($\alpha \leq 0.80$) sprawia, że algorytm traci stochastyczny charakter jeszcze przed przeszukaniem przestrzeni – skutkuje to gorszą jakością rozwiązania.
- Najlepszy wynik uzyskano dla $\alpha = 0.90$, choć różnice między wartościami 0,80–0,995 są niewielkie (rzędu 10^{-5}), co świadczy o względnej odporności algorytmu w tym zakresie.
- Wyraźnie gorszy wynik dla $\alpha = 0.999$ (0.038436 vs ~ 0.03482) wskazuje, że zbyt wolne chłodzenie uniemożliwia efektywną intensyfikację – algorytm „błądzi” do końca bez wyraźnej konwergencji.

Algorytm genetyczny – wielkość populacji pop_size

Testowane wartości: $pop_size \in \{50, 150, 300\}$

Stałe parametry: $K = 250$, bits_per_gene = 16, p_mut = 0,005, elityzm włączony.

pop_size	Funkcja celu	Stopa zwrotu	Ryzyko	Czas [s]
50	0.035428	19.93%	18.82%	1.349
150 ★	0.035123	19.73%	18.74%	3.967
300	0.035561	19.13%	18.86%	8.002

Zaobserwowane zależności:


- Mała populacja (pop_size = 50) daje gorszy wynik z powodu ograniczonej różnorodności genetycznej i ryzyka przedwczesnej konwergencji.
- Najlepszy wynik uzyskała populacja 150 osobników – stanowi dobry kompromis między czasem obliczeń a jakością.
- Większa populacja (pop_size = 300) nie poprawiła wyniku przy 250 pokoleniach – prawdopodobnie potrzebuje więcej generacji do pełnego wykorzystania swojej różnorodności.

5.2.4. Analiza wrażliwości


Funkcja run_sensitivity_analysis() uruchamia najlepsze konfiguracje SA ($\alpha = 0.90$) i GA (pop_size = 150) na 5 ziarnach losowości ({16, 123, 234, 2026, 9999}). Raportowane są: średnia, odchylenie standardowe, najlepszy i najgorszy wynik funkcji celu.

Algorytm	Śr. F	Std Dev F	Najlepsza F	Najgorsza F
SA	0.034803	0.000011	0.034787	0.034821
GA	0.035239	0.000213	0.035019	0.035628

5.2.5. Analiza wizualna (Wykresy porównawcze)



Wykres liniowy w skali logarytmicznej prezentujący ewolucję najlepszej dotąd wartości funkcji celu. Oś X jest znormalizowana do $[0, 1]$, co pozwala na wizualne porównanie algorytmów o różnej granulacji (SA: 5001 iteracji, GA: 250 pokoleń).



Klasyczny wykres ryzyko–zwrot (płaszczyzna $\sigma - \mu$) zawierający:

- numeryczną granicę efektywną (zielona linia ciągła),
- analityczną granicę Lagrange'a (szara linia przerywana),
- indywidualne spółki WIG15 (małe zielone punkty),
- najlepsze portfele SA i GA z wartością współczynnika Sharpe'a,
- poziomą linię docelową stopy zwrotu (15%).

5.3. Pliki wyjściowe i struktura katalogów

Plik	Opis
graphs/compare/porownanie_zbieznosci.png	Zbieżność funkcji celu (skala log, znormalizowana oś X)
graphs/compare/porownanie_granica.png	Granice efektywne i wyniki SA/GA na płaszczyźnie ryzyko–zwrot
tabele_wynikow.md	Tabele liczbowe z wynikami grid search, analizy wrażliwości i optymalnych wag

5.4. Główne wnioski z analizy

1. Wpływ harmonogramu chłodzenia (SA): W badanym zakresie ($\alpha \in \{0.80, 0.90, 0.99, 0.995, 0.999\}$) różnice w jakości rozwiązania są minimalne (rzędu 10^{-5}), co świadczy o odporności SA na dokładny dobór tempa chłodzenia – o ile mieści się ono w rozsądnym przedziale. Zdecydowanie gorszy wynik dla $\alpha = 0.999$ wskazuje, że zbyt wolne chłodzenie jest poważnym problemem.
2. Efektywność SA vs. GA: Symulowane Wyżarzanie z rzutowaniem na sympleks wykazuje znaczną przewagę – zarówno szybkościową (poniżej 1 sekundy vs ~4 sekundy dla GA 150), jak i jakościową (najlepsza F: 0.034787 vs 0.035123).
3. Stabilność: SA jest znacznie bardziej stabilny (std = 0.000011) niż GA (std = 0.000213). Duży rozrzut GA wynika ze stochastycznych operatorów genetycznych i binarnego kodowania – wynik zależy silnie od konkretnego przebiegu.
4. Jakość portfeli: Oba algorytmy zbliżają się do numerycznej granicy efektywnej Markowitza. SA osiąga współczynnik Sharpe'a 1,0243, GA – 1,0528. Warto odnotować, że mimo gorszej wartości funkcji celu, GA uzyskuje nieznacznie wyższy Sharpe, co wynika z nieco wyższej stopy zwrotu przy zbliżonym ryzyku. Wartości te odpowiadają konfiguracjom z grid search (rozdz. 5.2.3, K = 250); demonstracyjny przebieg GA z rozdz. 4.6 (seed 42, K = 400) daje Sharpe $\approx 1,038$ – różnica wynika ze stochastyczności GA i innej liczby pokoleń.

5. Zalecenie: W tym wariacie problemu Markowitza (15 aktywów WIG15, $w_i \geq 0$, cel 15%) rekomendowane jest Symulowane Wyżarzanie ($\alpha = 0.90$) – oferuje lepszy wynik funkcji celu, jest wielokrotnie szybsze i charakteryzuje się znacznie wyższą stabilnością wyników między uruchomieniami.

6. Bibliografia

- Markowitz, H. (1952). Portfolio Selection. *The Journal of Finance*, 7(1), 77–91. <https://doi.org/10.2307/2975974>
- Kirkpatrick, S., Gelatt, C. D., & Vecchi, M. P. (1983). Optimization by Simulated Annealing. *Science*, 220(4598), 671–680. <http://www.jstor.org/stable/1690046>
- Duchi, J., Shalev-Shwartz, S., Singer, Y., & Chandra, T. (2008). Efficient projections onto the ℓ_1 -ball for learning in high dimensions. *Proceedings of the 25th International Conference on Machine Learning*, 272–279. <https://doi.org/10.1145/1390156.1390191>
- Holland, J. H. (1992). *Adaptation in natural and artificial systems: An introductory analysis with applications to biology, control, and artificial intelligence*. The MIT Press. <https://doi.org/10.7551/mitpress/1090.001.0001>